

Resumen-Tema-6-para-examen.pdf



dcardenas11



Inteligencia Artificial



2º Grado en Ingeniería Informática



Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación
Universidad de Granada

Formamos
talento para un futuro
Sostenible



MÁSTER EN
**Big Data &
Business Analytics**

EOI Escuela de
organización
industrial

[saber más](#)

Importante

Puedo eliminar la publi de este documento con 1 coin

¿Cómo consigo coins? → Plan Turbo: barato
→ Planes pro: más coins

pierdo espacio



Necesito concentración

ali ali ooh
esto con 1 coin me
lo quito yo...

WUOLAH

Tema 6. Introducción al Aprendizaje Automático

Aprendizaje Automático (Machine Learning)

El aprendizaje es una capacidad fundamental de la inteligencia humana, que nos permite:

- Adaptarnos a cambios de nuestro entorno.
- Desarrollar una gran variedad de habilidades.
- Adquirir experiencia en nuevos dominios.

El aprendizaje automático cubre una amplia gama de fenómenos como:

- El perfeccionamiento de la habilidad.
- La adquisición del conocimiento.

Además, el aprendizaje es esencial en entornos desconocidos. En los programas de IA que hemos visto (Búsqueda, SBC, Planificación, ...) el límite está en el conocimiento que se les ha proporcionado. Esto quiere decir que no resuelven problemas más allá de esos límites.

El aprendizaje modifica el mecanismo de decisión del agente para mejorar su comportamiento.

¿De qué se trata?

Hay que hacer aprender a una máquina para hacer que un programa sea capaz de actuar o tomar decisiones en entornos desconocidos o ante entradas que desconocemos y que además pueda actuar ante situaciones no previstas.

En realidad vamos a desconocer muchos de los aspectos que nos hacen falta para actuar en esas circunstancias pero en general nos vamos a encontrar con situaciones en las que:

- O bien necesitamos una habilidad y tenemos que aprender a desarrollarla.
- Necesitamos un conocimiento y debemos adquirirlo.

La idea fundamental de todo esto es que vamos a adquirir las habilidades o conocimientos de forma automática sin la intervención de algún humano. Vamos a usar aprendizaje automático donde tengamos tareas difíciles de programar, en aplicaciones auto adaptables y en la minería de datos.

Un programa de ordenador se dice que **aprende de la experiencia E con respecto a alguna clase de tareas T y a alguna medida de comportamiento P**, si su comportamiento en tareas de T, medido a través de P, mejora con la experiencia E.

Hay varias estrategias de aprendizaje algunas de ellas son las que vemos en la diapositiva pero la más usada en aprendizaje automático es el aprendizaje a partir de ejemplos cuya idea es que a partir de un número elevado de ejemplos se aprende.

Tipos de Aprendizaje

Podemos tener:

- Aprendizaje memorístico
- Aprendizaje a través de consejos
- Aprendizaje en la resolución de problemas

WUOLAH

- Aprendizaje a partir de ejemplos: inducción
- Aprendizaje basado en explicaciones
- Aprendizaje a través de descubrimiento
- Aprendizaje por analogía

Nos centramos, como ya hemos dicho antes, en el **aprendizaje a partir de ejemplos**, el aprendizaje inductivo.

Aprendizaje Inductivo

La idea es proporcionar un conjunto de ejemplos y con los ejemplos obtener un modelo que explica esos ejemplos u observaciones. Es decir, el modelo me tiene que decir qué está ocurriendo e incluso predecir qué es lo que va a ocurrir.

Los ejemplos son pares de valores $(x, f(x))$ donde x puede ser un dato numérico o un vector y $f(x)$ lo que se pretende reconocer. Lo que quiero es predecir si ante una nueva entrada desconocida se cumple $f(x)$ (por ejemplo si un paciente tiene una enfermedad), es decir, quiero aprender a partir de los ejemplos un modelo que me explique un comportamiento general y a esto se le llama inducción.

En estos problemas no podemos deducir porque no tenemos conocimiento de partida, partimos de ejemplos pero no de conocimiento. Nuestro modelo a buscar será $f(x)$ generando varias hipótesis de qué puede ser $f(x)$ y validando estas hipótesis con los ejemplos que me proporcionan (ejemplos de entrenamiento). Por tanto, *aprender va a ser buscar en un espacio de hipótesis la hipótesis que mejor se acerca a mi función f teniendo en cuenta los ejemplos de entrenamiento.*

Tipo de realimentación

Hemos visto que en el aprendizaje inductivo los ejemplos son pares de entrada/salida. A este tipo de aprendizaje se le denomina **aprendizaje supervisado** porque necesitamos un supervisor externo que proporciona información para asociar a cada entrada una salida.

Hay otros dos tipos de aprendizaje dependiendo de la retroalimentación que nos proporcione el entorno:

- **Aprendizaje no supervisado:** Aprender a partir de patrones de entradas para los que no se especifican los valores de su salidas.
- **Aprendizaje por refuerzo:** Aprender a partir del refuerzo, en forma de recompensa o castigo, que devuelve el entorno.

Métodos de aprendizaje supervisado

1. Métodos basados en modelos: representan el conocimiento aprendido en algún lenguaje de representación (el resultado del aprendizaje es un modelo). Este es el más común.
2. Métodos basados en instancias: representan el conocimiento aprendido como un conjunto de prototipos descritos en el mismo lenguaje usando para representar la evidencia.
 - El resultado es un método de acceso/asociación entre las nuevas entradas y los ejemplos ya conocidos.

Conceptos esenciales en el aprendizaje inductivo

Vamos a asumir que la función es de variable numérica y que los ejemplos son un conjunto de pares numéricos $(x, f(x))$.

¿VAS A ESTUDIAR EN GRANADA?

Descubre la **Residencia Universitaria Xior** perfecta para ti.

📍 XIOR GRANADA



Habitaciones y pisos para
estudiantes en Granada
en **Xior Student Housing**.

Más info



Xior, Tu Hogar Lejos de Casa

XIOR
STUDENT HOUSING

Inteligencia Artificial



Comparte estos flyers en tu clase y consigue más dinero y recompensas



Banco de apuntes de la

WUOLAH

1

Imprime esta hoja

2

Recorta por la mitad

3

Coloca en un lugar visible para que tus compis puedan escanar y acceder a apuntes

4

Llévate dinero por cada descarga de los documentos descargados a través de tu QR



- **Generalización:** Una hipótesis estará bien generalizada si puede predecir ejemplos que no se conocen. Es decir si la función que hemos encontrado en el proceso de aprendizaje devuelve valores esperados o adecuados cuando le paso ejemplos desconocidos.
- **Consistencia:** una hipótesis es consistente si se ajusta completamente a los datos de partida. No siempre es deseable que una hipótesis se ajuste a todos los datos de partida o entrenamiento.
 - Para elegir entre múltiples hipótesis consistentes vamos a acudir a la **Navaja de Ockham** que establece que ante dos explicaciones de un mismo fenómeno la más simple prevalece.
- **Simplicidad:** La definición de simplicidad va a depender del problema en el que nos encontremos.

En un proceso de aprendizaje por tanto hay que encontrar un equilibrio entre hipótesis que se ajustan a los datos de entrenamiento pero que son más complejas o hipótesis que son más simples según la Navaja de Ockham pero que no se ajustan a todos los ejemplos.

Representación

Además de estos conceptos, otro aspecto del proceso de aprendizaje esta relacionado con el esquema que vamos a usar para representar las hipótesis de nuestro espacio de búsqueda. Hay varios modelos para representar hipótesis como:

- Árboles de decisión
- Reglas
- Redes neuronales

En todo caso la elección del modelo de representación que yo use no es inmediato ni simple y esta elección va a determinar si mi problema de aprendizaje es realizable o no.

Se dice que un problema de aprendizaje es **realizable** si el espacio de hipótesis contiene la función verdadera. Esto es un concepto teórico que en la práctica es difícil de llevar a cabo.

Árboles de decisión

Conceptos básicos

Un árbol de decisión toma como entrada un objeto o una situación descrita a través de un conjunto de atributos y devuelve una "decisión", el valor previsto de la salida dada la entrada. A esta solución también se la denomina **clase**.

Estos árboles pueden recibir como entrada atributos que tomen tanto valores discretos (booleans o enumerados) como continuos. Y en cuanto a la salida tenemos:

- Si los valores de las etiquetas (clases) son discretos estamos hablando de un problema de clasificación (en los que nos vamos a centrar)
- Si los valores de la salida son continuos estamos ante un problema de regresión.

Un árbol de decisión tiene una estructura de árbol normal donde:

- Los nodos no terminales representan una pregunta o una condición sobre un atributo de la tabla.
- Los arcos representan posibles valores de ese atributo.
- Los nodos hoja representan un posible valor de la salida (cierto o falso solamente para nosotros).

Importante

Puedo eliminar la publi de este documento con 1 coin

¿Cómo consigo coins? → Plan Turbo: barato
→ Planes pro: más coins

pierdo espacio



Necesito concentración

ali ali ooh
esto con 1 coin me
lo quito yo...

WUOLAH



En conclusión, podemos usar un árbol de decisión como una función que a partir de una entrada lo que va a hacer va a ser recorrer el árbol haciendo preguntas teniendo en cuenta los nodos del árbol hasta que encuentre un nodo hoja y devolverá el valor del nodo hoja.

Construcción de un árbol de decisión

Consiste en un proceso en el que vamos seleccionando atributos y los vamos añadiendo al árbol hasta que todos los ejemplos estén cubiertos. En este proceso hay dos aspectos a los que le debemos prestar atención:

1. Por un lado el número de preguntas que se tiene que hacer el árbol para llegar a una clasificación, es decir, el número de nodos intermedios del árbol, cuantos menos nodos tenga mejor será.
2. Por otro lado tenemos que decidir qué criterio usamos para seleccionar unos atributos u otros. Para ello tenemos que observar que cada vez que seleccionamos un atributo creamos una división o partición en el conjunto de ejemplos.

Inducción

Ejemplos y expresividad

Ejemplos positivos y negativos

Ya sabemos que en el aprendizaje por inducción trabajamos con ejemplos. Estos ejemplos se podrán clasificar en:

- **Positivos:** Los ejemplos positivos son aquellos en los que la meta que se tenga es verdadera.
- **Negativos:** son aquellos en los que es falsa.

El conjunto de ejemplos completo se denomina **conjunto de entrenamiento**.

Expresividad de los árboles de decisión

Los árboles de decisión pueden expresar cualquier función a partir de los atributos de entrada. Por ejemplo, para funciones Booleanas, cada fila de la tabla de verdad se traslada a un camino del árbol:

Para cualquier conjunto de entrenamiento vamos a poder construir un árbol de decisión consistente de forma trivial. Pero seguramente no será bueno para generalizar. Por eso es preferible encontrar árboles de decisión más compactos.

Inducción de árboles

La idea para la construcción de árboles de decisión es que manteniendo la consistencia los árboles sean más compactos que el árbol trivial. Es decir queremos un árbol consistente y simple. Podemos construirlo de varias formas:

- **Trivial:** crear una ruta del árbol por cada instancia de entrenamiento, esto nos lleva a árboles grandes y poco generalizados.
- **Óptimo:** el árbol más pequeño posible compatible con todas las instancias. Siguiendo la filosofía de la navaja de Ockham su simplicidad dependerá del número de nodos. En este caso encontrar un árbol lo más pequeño posible y consistente es un problema de optimización que para datos grandes es inviable computacionalmente.

WUOLAH

- Pseudo-óptimo: vamos a construir el árbol por pasos, en cada paso vamos a seleccionar un atributo y lo vamos a incluir en el árbol y el criterio de selección va a depender de la calidad de la partición o división que produce el atributo en el conjunto de ejemplos.
 - Este concepto de calidad se implementará mediante una valoración heurística de atributos.

Elección de atributos

Un buen atributo debe dividir el conjunto de ejemplos en subconjuntos que sean o todos positivos o todos negativos.

Con este criterio de selección de atributos basado en información heurística vamos a ver un algoritmo general para aprender árboles de decisión.

Decision Tree Learning (DTL)

Este algoritmo lleva acabo una estrategia DYV de manera que en cada paso selecciona un atributo de forma greedy (el mejor entre todas las alternativas) . Con este atributo seleccionado va a crear una partición de varios subconjuntos de elementos y recursivamente se aplicará el mismo algoritmo con cada uno de los subconjuntos de la partición.

Tenemos 4 puntos esenciales dentro de la decisión:

1. No quedan ejemplos: en este caso se va a devolver un valor por defecto asociado a la mayoría de ejemplos en el nodo padre.
2. Se llega a un nodo hoja, es decir, todos los ejemplos son positivos o negativos: en este caso lo que se devuelve es la etiqueta que se corresponde o bien con los datos positivos o con los negativos.
3. No quedan atributos y aún quedan ejemplos: se devuelve el valor de la etiqueta de la mayoría de ejemplos.
4. Quedan ejemplos positivos y negativos y todavía no se han agotado los ejemplos ni hemos llegado a un nodo hoja: se continúa.

```
function DTL(examples, attributes, default) returns a decision tree
  if examples is empty then return default
  else if all examples have the same classification then return the classification
  else if attributes is empty then return MODE(examples)
  else
    best ← CHOOSE-ATTRIBUTE(attributes, examples)
    tree ← a new decision tree with root test best
    for each value  $v_i$  of best do
       $examples_i \leftarrow \{\text{elements of } examples \text{ with } best = v_i\}$ 
      subtree ← DTL(examplesi, attributes − best, MODE(examplesi))
      add a branch to tree with label  $v_i$  and subtree subtree
    return tree
```

1. No quedan ejemplos: valor por defecto calculado a partir de la mayoría en el nodo padre.
2. Todos los ejemplos son positivos o negativos.
3. No quedan atributos: voto de la mayoría de los ejemplos que quedan.
4. Quedan ejemplos positivos y negativos.