

Servidores Web de Altas Prestaciones



¿Cuánto tiempo está disponible un sistema para dar respuesta a usuarios?
¿El sistema se adapta bien a más peticiones?



Tema 2: Disponibilidad y Escalabilidad



ICAR

INGENIERÍA DE COMPUTADORES,
AUTOMÁTICA Y ROBÓTICA



**UNIVERSIDAD
DE GRANADA**




Índice





Introducción



Usuarios



Administradores

Sitio web esté operativo SIEMPRE
que se conecte


Sitio web se adapte a más
peticiones

Tiempo de respuesta sea
RÁPIDO

Tiempo de respuesta sea
RÁPIDO

DISPONIBILIDAD

ESCALABILIDAD






Introducción

DISPONIBILIDAD



ESCALABILIDAD




Balanceador de carga

- Intermediario entre usuarios y servidores
- Distribuye solicitudes entrantes entre múltiples servidores
- Dirige tráfico a servidores adecuados





Índice





Alta disponibilidad

Es un protocolo de **diseño del sistema** y su implementación asociada que asegura un cierto **grado absoluto de continuidad operacional** durante un período de medición dado.

Capacidad de aceptar visitas las 24h todos los días.





Alta disponibilidad

<http://www.isitdownrightnow.com>



Is Ugr down? Check all t

Ad closed by Google

Ugr.es Server Status Check
Ugr.es
favicon

Website Name:	Ugr
URL Checked:	ugr.es
Response Time:	370.51 ms.
Last Down:	More than a week ago


UP Ugr.es is UP and reachable by us.
Please check and report on local outages below ...

Report an Issue



Hipertextual
@Hipertextual

La caída de Amazon S3 rompe medio internet



La caída de Amazon S3 rompe medio internet
La caída de una de las zonas más populares y...
hipertextual.com






Alta disponibilidad

<https://outage.report/whatsapp>

Home » WhatsApp » Outage Map


Is WhatsApp Down Right Now?

See if WhatsApp is down or having service issues today




Everything is down - 50%
Mobile app not working - 25%
Message send problems - 25%

Outage History



Reports Dynamics EST (GMT -05:00)




Received 8 reports, originating from United States of America, Mexico, Jamaica, Portuguese Republic, Russia and 2 more countries

WhatsApp Outage Map Live



Riga	Everything is down	36m
Castro Valley	Message send problems	4h
Flemington	Mobile app not working	7h





Alta disponibilidad



Wardog
@mundowdg



Tuve un jefe que cuando caía su
único servidor (nada de
redundancia, eso es tirar el dinero)

siempre gritaba:

"¡A que ésto no le pasa a Facebook!
¡Pues si Facebook puede hacerlo es
que se puede hacer!"

Cuán atrevida es la ignorancia y qué
puta es la informática.





Alta disponibilidad

Cuando un sitio no está disponible se dice que se ha caído o sufre un problema de no-disponibilidad:

Tiempo de no-disponibilidad (downtime) programado.

Tiempo de no-disponibilidad (downtime) no programado.

Sólo debería haber “tiempos de no-disponibilidad programados” (y lo más cortos posibles)

actualizaciones del SO, de aplicaciones o de hardware





Alta disponibilidad

Medir la disponibilidad dando un porcentaje.

Escala "punto nueve":

$$100 - (\text{tiempoCaído} / \text{periodoTiempo}) * 100$$

Por ejemplo:

caída de 1h en un día → 95.83333% de disponibilidad

caída de 1h en una semana → 99.404% de disponibilidad

Se persigue tener un 100% de disponibilidad.





Alta disponibilidad

Un 100% de disponibilidad es no sufrir caídas no-programadas

Los sitios web se conforman con alcanzar un 99.9% o 99.99%

Disponibilidad (%)	Periodo de un año
90%	36.5 días
95%	18.25 días
98%	7.3 días
99%	3.65 días
99.9%	8.76 horas
99.99%	52.56 minutos
99.999%	315 segundos
99.9999%	31.5 segundos





Alta disponibilidad

Otra forma de escribir la ecuación:

$$\text{Availability} = \text{Uptime} / (\text{Uptime} + \text{Downtime})$$

Horas en un año (periodo) = 8760

Horas caído (tiempo caído) = 1830

Tiempo en activo = $8760 - 1830 = 6930$

Disponibilidad = $6930 / 8760 = 0.791$

Disponibilidad = $100 - (1830 / 8760) * 100 = 79.1$





Alta disponibilidad

¿Cómo podemos calcular la disponibilidad de un sistema?

Si tenemos dos servidores (web+BD) y cada uno tiene 99%, la disponibilidad del sistema será $99\% \times 99\% = 98.01\%$

Si cada uno puede estar caído 3.65 días, podemos esperar que el sistema esté caído un total de 7.3 días en un año.

Peor caso: que esté caído 3.65 días el servidor web y justo después caiga el de BD otros 3.65 días

Disponibilidad (%)	Periodo de un año
90%	36.5 días
95%	18.25 días
98%	7.3 días
99%	3.65 días
99.9%	8.76 horas
99.99%	52.56 minutos
99.999%	315 segundos
99.9999%	31.5 segundos





Alta disponibilidad

Pero los sistemas reales son más complejos...

Hay muchos más elementos y algunos redundantes.

Necesitamos fórmulas algo más complejas:

(1) Para un sistema **s** con **n** componentes, la disponibilidad del sistema se calcula como:

$$A_s = A_{c1} * A_{c2} * A_{c3} * \dots A_{cn}$$

<u>Component</u>	<u>Availability</u>
Web	85%
Application	90%
Database	99.9%
DNS	98%
Firewall	85%
Switch	99%
Data Center	99.99%
ISP	95%

Ejemplo de sitio de comercio electrónico con varios puntos de fallo





Alta disponibilidad

En ese ejemplo, si cualquier componente falla, supondremos que el sistema falla.

La disponibilidad será:

$$85\% * 90\% * 99.9\% * 98\% * 85\% * 99\% * 99.99\% * 95\% = \underline{59.87\%}$$

¿Parece baja? Al usuario le importa que el sistema proporcione el servicio. Si está caído, le dará igual que sea por el cortafuegos o por fallo de una aplicación web.

¿cómo mejorar la disponibilidad de este sistema?





Alta disponibilidad

¿y si mejoramos la disponibilidad del servidor web y cortafuegos?

(2) Si el sistema tiene un componente replicado, la disponibilidad de esa parte del sistema completo será:

$$A_{\text{NuevoC}} = A_{c1} + ((1 - A_{c1}) * A_{c2})$$

Component	Availability
Web	85%
Application	90%
Database	99.9%
DNS	98%
Firewall	85%
Switch	99%
Data Center	99.99%
ISP	95%

En el ejemplo, añadir un segundo servidor web hará:

$$\text{disponibilidad_web2} = 0,85 + (1 - 0,85) * 0,85 = 0,9775$$

$$\text{disponibilidad_web2} = 85\% + ((100\% - 85\%) * 85\%) = \mathbf{97.75\%}$$





Alta disponibilidad

Antes teníamos un 59.87% para todo el sistema.

¿Qué disponibilidad tendremos si replicamos el servidor web y el cortafuegos?

Cada uno de esos componentes (servidor web y cortafuegos) tendrán ahora 97.75%

Y el sistema:

$$97.75\% * 90\% * 99.9\% * 98\% * 97.75\% * 99\% * 99.99\% * 95\% = \underline{79.10\%}$$

Hemos mejorado en 19.23%

Pasaríamos de unas 3500 horas de no-disponibilidad al año a unas 1830 horas de no-disponibilidad al año.





Alta disponibilidad

Si replicáramos cada elemento de red, servidores e ISP, dejando un solo centro de datos:

$$97.75\% * 99\% * 99.9999\% * 99.96\% * 97.75\% * 99.99\% * 99.99\% * 99.75\% = \underline{94.3\%}$$

Mejorado en 34.43%

Component	Availability
Web	97.75%
Application	99%
Database	99.9999%
DNS	99.96%
Firewall	97.75%
Switch	99.99%
Data Center	99.99%
ISP	99.75%

Pasaríamos de unas 3500 horas de no-disponibilidad al año a unas 500 horas de no-disponibilidad al año.





Alta disponibilidad

Si generalizamos la última ecuación para cuando replicamos dos componentes:

$$A_{\text{nuevo}} = AC_{n-1} + ((1 - AC_{n-1}) * AC_n)$$

Así, si hemos añadido un tercer servidor web:

$$\text{disponibilidad_web3} = 97.75\% + (1 - 97.75\%) * 85\% = 99.6625\%$$

Y si añadimos un cuarto servidor web:

$$\text{disponibilidad_web4} = 99.6625\% + (1 - 99.6625\%) * 85\% = 99.949\%$$





Alta disponibilidad

Ejercicio T2.1:

Calcular la disponibilidad del sistema si tenemos dos réplicas de cada elemento (en total 3 elementos en cada subsistema).

Disponibilidades iniciales

Component	Availability
Web	85%
Application	90%
Database	99.9%
DNS	98%
Firewall	85%
Switch	99%
Data Center	99.99%
ISP	95%

Con 2 elementos en cada subsistema

Component	Availability
Web	97.75%
Application	99%
Database	99.9999%
DNS	99.96%
Firewall	97.75%
Switch	99.99%
Data Center	99.99%
ISP	99.75%





Alta disponibilidad

¿Cómo se consigue mejorar la disponibilidad?

El uso de subsistemas redundantes y monitorizarlos mejora la disponibilidad del sistema global.

Surgen conceptos derivados:



- disponibilidad de red



- disponibilidad de servidor



- disponibilidad de aplicación

Si la disponibilidad de red es baja, quizás haya que mejorar el ancho de banda, y no tenga sentido centrar esfuerzos en mejorar las aplicaciones.





Alta disponibilidad



Disponibilidad de la red

El diseño debe tener redundancia a todos los niveles:

Conexión a Internet

Routers/cortafuegos/balanceadores

Servidores

Si hay que recortar costes, algún elemento puede ser único: p.ej. el router, si el proveedor se compromete a reemplazarlo en pocas horas.





Alta disponibilidad



Disponibilidad del servidor

Casi cualquier elemento hardware del servidor puede fallar: CPU, memoria, discos, placas, etc.

Existen productos en el mercado con cualquier elemento duplicado.





Alta disponibilidad



Disponibilidad del servidor

Puesto que casi cualquier elemento hardware del servidor puede fallar...

Se pueden configurar los servidores con redundancia mediante el software.

Mejora de la escalabilidad.





Alta disponibilidad



Disponibilidad del servidor

Monitorizar la disponibilidad con las herramientas del SO.

El desarrollador Emerson ofrece herramientas para monitorizar hardware y software.

The screenshot shows the Emerson website's navigation bar with the Emerson logo, 'AUTOMATION SOLUTIONS', 'COMMERCIAL & RESIDENTIAL SOLUTIONS', a search icon, and a shopping cart icon. Below the navigation bar is a breadcrumb trail: 'Home / DeltaV™ OPC Data Access Server Redundancy'. The main content area features a tabbed interface with 'IMAGES (1)' selected and 'VIDEOS (0)' unselected. Under the 'IMAGES (1)' tab, there is a large image of a Dell monitor displaying a complex network diagram of the DeltaV system architecture. To the right of the image, the title 'DeltaV™ OPC Data Access Server Redundancy' is followed by a descriptive paragraph: 'The DeltaV™ OPC Data Access Server provides a fast and efficient means for transferring data between the DeltaV system and OPC Data Access client applications. With redundant OPC servers, you don't have to worry about a failure of an OPC server or the Application Station interrupting your data transfer and causing costly downtime. Using redundant OPC servers you are automatically protected against single point OPC server hardware and software failures.' Below the text are two green buttons: 'CONTACT US >' and 'LEARN ABOUT >'.





Alta disponibilidad



Disponibilidad de las aplicaciones

Complicado medir las prestaciones de las aplicaciones.

El funcionamiento de unos módulos afecta al de otras aplicaciones (dependencias).

El desarrollador del SO suele facilitar herramientas para monitorizar también las aplicaciones en ejecución.





Alta disponibilidad



Disponibilidad de las aplicaciones

Dependencia entre aplicaciones o módulos de aplicación:

Si un módulo falla, el proceso no se completa, y la experiencia del usuario es mala.


Desarrollar aplicaciones robustas -> hacerlas redundantes.

Si una parte del proceso falla, que haya una alternativa para completarlo.





Índice



Introducción

Concepto de alta disponibilidad

Concepto de escalabilidad

Escalar un sitio web

Conclusiones





Escalabilidad



Cuando una persona sufre estrés, su capacidad para afrontar tareas se ve mermada.



Cuando un sistema experimenta estrés, su capacidad para dar servicio también se ve afectada.



ERROR 500

INTERNAL SERVER ERROR





Escalabilidad



Incremento del nivel de estrés:

Cambios en las aplicaciones

Fallos o caídas de algunas partes del sistema

Incremento del número de máquinas

Incremento repentino del número de usuarios del sitio

Etc.

La escalabilidad se refiere a la capacidad de un sistema de manejar la carga, y el esfuerzo para adaptarse al nuevo nivel de carga.






Definición

capacidad de un sistema de manejar la carga, y el esfuerzo para adaptarse al nuevo nivel de carga

capacidad de adaptación y respuesta de un sistema con respecto al rendimiento del mismo a medida que aumentan de forma significativa el número de usuarios del mismo.





Escalabilidad



Si un sitio gana popularidad, o si llega una fecha señalada, puede incrementarse su carga.

Para manejar esa carga, las empresas tienen más servidores de los necesarios normalmente.

Decidir cómo añadir más recursos al sistema web es crucial en el diseño inicial y en el mantenimiento.





Escalabilidad



Dos tipos de escalado:

Ampliación vertical:

incrementar la RAM, CPU, disco de un servidor.

Ampliación horizontal:

añadir máquinas a algún subsistema (servidores web, servidores de datos, etc).

En ocasiones una ampliación vertical puede ser suficiente.






Escalabilidad



Escalado vertical:



Si ponemos una máquina más potente, podrá dar servicio hasta aquí, pero a partir de ese nivel ya no podrá atender más carga



Esta máquina sólo puede dar servicio hasta este punto.






Escalabilidad



Escalado horizontal:



Cada máquina incrementa un poco la escalabilidad.





¿Cómo analizar la sobrecarga?

Si la CPU está cerca del 100% de utilización y el resto de subsistemas no está sobrecargado, sustituir por una CPU más potente.

Si el uso de RAM es muy alto, veremos un uso alto de disco (por swapping). Incrementando la cantidad de RAM mejoraremos el rendimiento.

Un ancho de banda insuficiente afectará al rendimiento. Contratando una mejor conexión será suficiente.





Escalabilidad



Transformar el servidor web en una granja web

Proceso complejo.

Preparar aplicaciones para distribuir la carga.

Configurar la red para soportar tráfico creciente.


Configuración del balanceo de carga para formar un cluster web para cada servicio.

Una granja web puede tener varios clusters web.





Índice



Introducción

Concepto de alta disponibilidad

Concepto de escalabilidad



Escalar un sitio web


Conclusiones





Escalar un sitio web

Tenemos que configurar tres niveles:



- máquinas como servidores web



- aplicaciones



- almacenamiento






Escalar un sitio web



El nivel web se puede configurar balanceando la carga:

uso de una máquina
con software específico






Escalar un sitio web



También se puede usar un balanceador hardware:

Local Director (Cisco)
ServerIron (Foundry)
BigIP (F5)





Escalar un sitio web



El balanceador pasa peticiones a los servidores según el tráfico de la red.

Hay varios algoritmos para decidir qué máquina final servirá cada petición:

- Por turnos (round-robin)
- Según el menor número de conexiones
- Por ponderación
- Por prioridad
- Según el tiempo de respuesta





Escalar un sitio web



Escalar el nivel de aplicaciones requiere diseñar el software pensando en que se ejecute en varios servidores:

- Paralelismo
- Transparencia de ubicación: no debe haber dependencia de una máquina concreta para ejecutarse la aplicación.

Es importante diseñar las aplicaciones desde el principio para que se ejecuten en varios servidores.

Adaptar posteriormente una aplicación dependiente de cierto servidor puede ser costoso.





Escalar un sitio web



Escalar el nivel de almacenamiento es complejo y depende del tipo de servicios a ofrecer:

LDAP: Protocolo Ligero de Acceso a Directorios

NFS: Sistema de archivos de red

Bases de datos

Cada uno de estos mecanismos suele requerir mecanismos y configuraciones diferentes.





Conclusiones

1.Importancia de la Alta Disponibilidad:

1. Fundamental para garantizar la operatividad constante de los servicios web.
2. Minimiza el tiempo de inactividad, tanto programado como no programado.

2.Cálculo de la Disponibilidad:

1. Se mide en términos porcentuales para evaluar la confiabilidad del sistema.
2. Un objetivo es alcanzar la máxima disponibilidad posible.

3.Escalabilidad:

1. Capacidad de adaptación a la carga creciente y a las demandas cambiantes.
2. Incluye estrategias de ampliación horizontal y vertical.

4.Equilibrio entre Disponibilidad y Escalabilidad:


1. Diseño y planificación cuidadosos son clave para un sistema eficaz.
2. Considerar el impacto de las decisiones de escalabilidad en la disponibilidad.

5.Desafíos y Estrategias:

1. La implementación de soluciones efectivas requiere un entendimiento profundo tanto de la teoría como de la tecnología aplicada.
2. Estrategias innovadoras y adaptativas son esenciales para mantenerse al día con las tendencias actuales y futuras.



Servidores Web de Altas Prestaciones



¿Cuánto tiempo está disponible un sistema para dar respuesta a usuarios?
¿El sistema se adapta bien a más peticiones?



Tema 2: Disponibilidad y Escalabilidad



ICAR

INGENIERÍA DE COMPUTADORES,
AUTOMÁTICA Y ROBÓTICA



**UNIVERSIDAD
DE GRANADA**
